Память в ОС

Сегментная адресация

- Физическая память делится на куски разного размера — сегменты
- За каждым процессом закрепляются несколько сегментов: сегмент с кодом, сегмент с данными, сегмент со стеком итд
- Обращения между сегментами контролируются ОС
- Выделение памяти в худшем случае требует переноса сегмента по другому адресу – что делать с уже существующими указателями? (например, для связных списков)
- *Фрагментации памяти*

Виртуальная память и страничная адресация

- Вся физическая память делится на ***фреймы*** — куски равного размера (4096 байт на x86)
- Каждому процессу выделяется своё *изолированное 64-битное адресное пространство*
- Эта *виртуальная память* делится на ***страницы*** аналогично фреймам
- Каждой странице в адресном пространстве может соответствовать какой-то фрейм

Виртуальная память

- Последовательные страницы в виртуальной памяти могут быть непоследовательны в физической
- Две страницы могут траслироваться в один и тот же фрейм
- Фрейм может иметь несколько образов в разных адресных пространствах (разделяемая память)

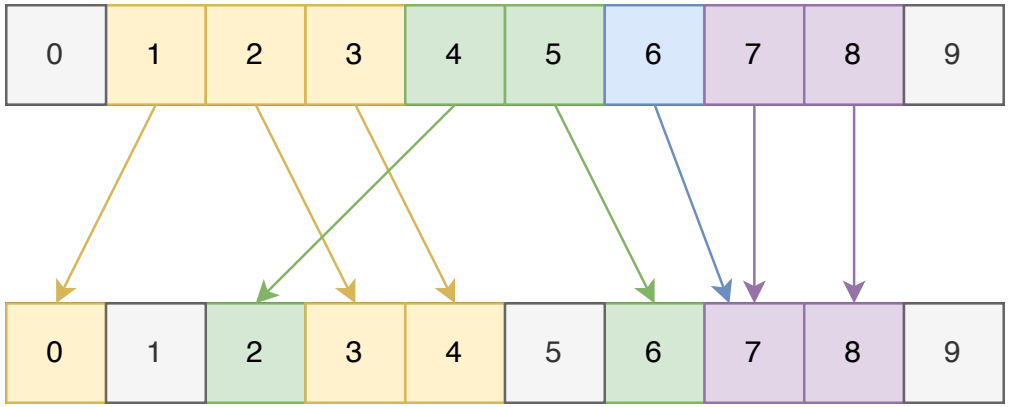

Страничная адресация

- Как хранить отображение страниц во фреймы?
- Всего существует $\frac{2^{64}}{2^{12}} = 2^{52}$ страниц памяти
- Если каждая страница описывается 8 байтами, то потребуется 2^{60} байт (эксабайт) памяти
- Нужен более экономный способ хранить это отображение!

Hierarchical page tables

- Идея: давайте сделаем многоуровневые таблицы: сначала поделим всё пространство на части, каждую из этих частей ещё на части итд
- Не храня лишние «дыры» мы будем экономить место

x86: 4-level page tables

- x86 использует четырёхуровневые таблицы: P4, P3, P2, P1
- Каждая таблица занимает ровно 4096 байт и содержит 512 PTE (page table entry) по 8 байт
- Каждая запись ссылается на адрес следующей таблицы, последняя таблица ссылается на адрес фрейма
- Адрес текущей P4 содержит `cr3`

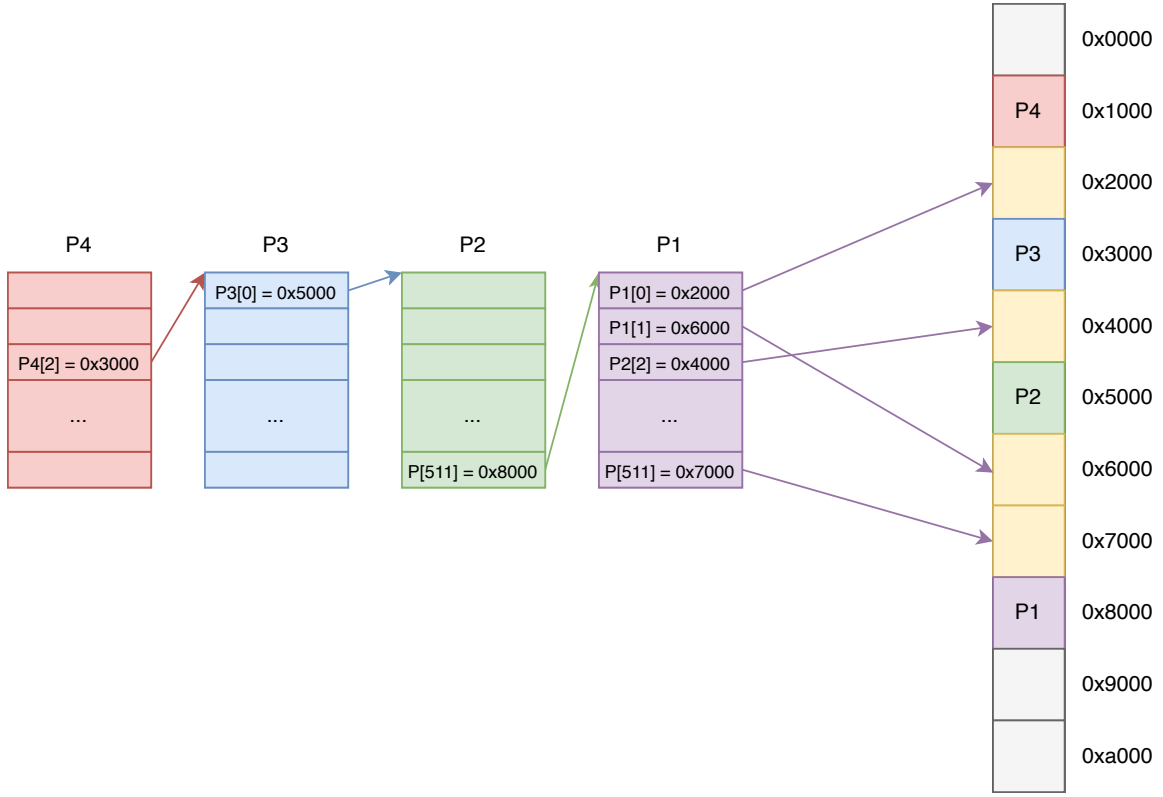

PTE

- Адрес следующей таблицы или фрейма всегда содержит 12 нулей на конце – они используются в качестве *флагов страниц*
- Они хранят **флаги страниц**:
  - `PTE_PRESENT = 1 << 0` : должен быть установлен, если PTE существует
  - `PTE_WRITE = 1 << 1` : если установлен, то страница доступна на запись
  - `PTE_USER = 1 << 2` : доступна ли страница из юзерспейса
  - `PTE_NX = 1 << 63` : если установлен, то инструкции на странице нельзя исполнять
- Флаги имеют иерархическую видимость: если в P2 `PTE_WRITE = 0`, а в P4 — `1`, то страница будет *недоступна* на запись

PTE

- Также существуют флаги, которые записывает *сам процессор*:
  - `PTE_ACCESSED = 1 << 5` : если PTE была использована при трансляции адреса
  - `PTE_DIRTY = 1 << 6` : если PTE была использована при трасляции адреса для записи
- ОС может обнулять самостоятельно эти флаги, процессор их перезапишет

Виртуальные адреса

- Каждый адрес уникально задаёт последовательность PTE в разных таблицах + 12 бит смещения
- На индекс каждой PTE требуется 9 бит, $\Rightarrow$ лишь $9 \times 4 + 12 = 48$ бит используется для адресации
- Все остальные биты должны копией 47 бита – т.н. *канонический адрес*
- Обращение к кеканоническим адресам приводит к ошибке (обрабатываемой) в процессоре

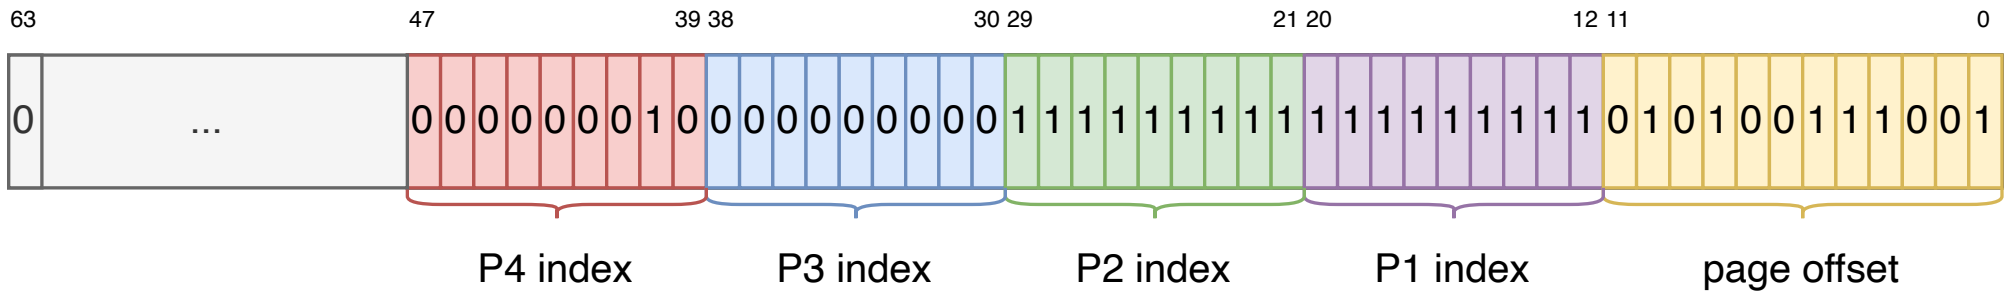

Виртуальные адреса

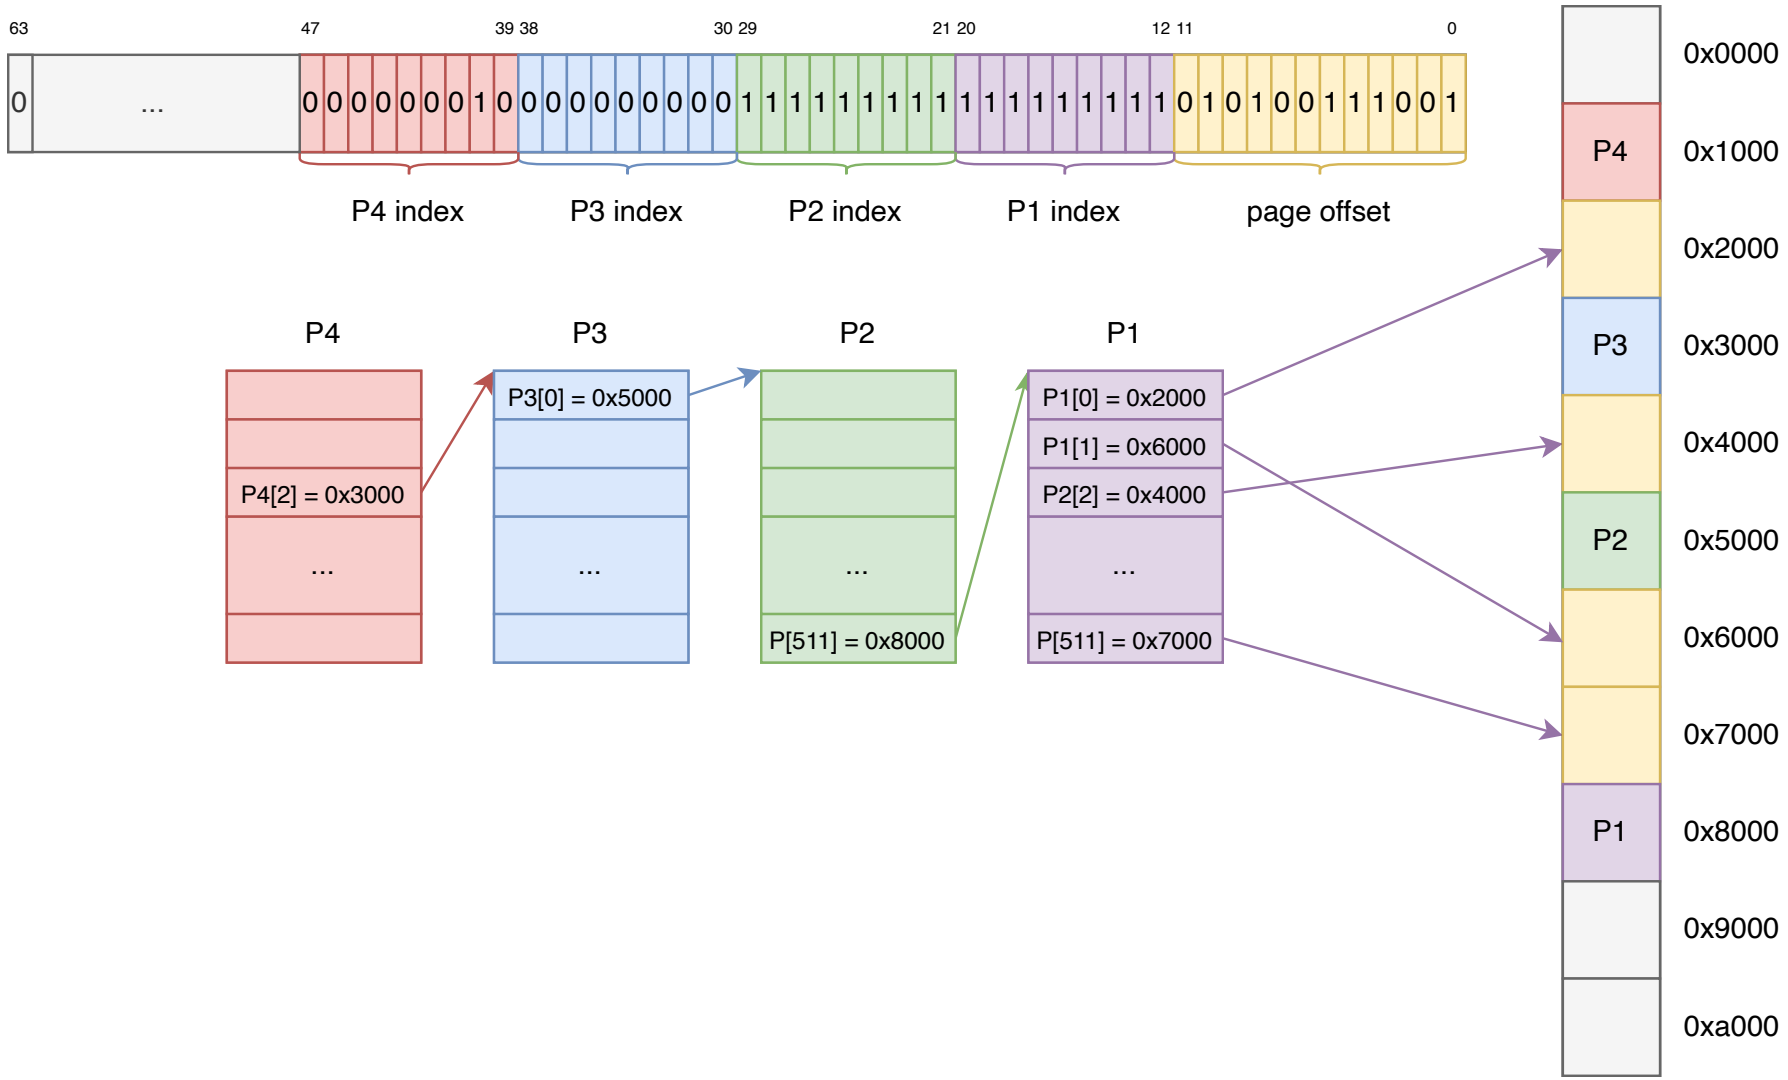

TLB

- Процесс трансляции виртуального адреса в физичесий достаточно медленный
- Translation Lookaside Buffer – кэш виртуальных адресов
- TLB сбрасывается каждый раз, когда меняется адресное пространство

Кэши процессора

Кэши процессора: локальность данных

- **Temporal locality**: если процесс прочитал какую-то память, то скорее всего, скоро он прочитает её ещё раз
- **Spatial locality**: если процесс прочитал какую-то память, то, скорее всего, скоро он прочитает память следующую за ней

```
int s = 0;
for (size_t i = 0; i < n; i++) {
    s += arr[i];
}
```

Кэши процессора: локальность данных

- Перемножение матриц «в лоб» – плохой способ
- Обращения к `b[k][j]` происходят не локально!
- Решение: расположить матрицу `b` по столбцам (column major layout)

```
for (size_t i = 0; i < n; i++) {
    for (size_t j = 0; j < n; j++) {
        for (size_t k = 0; k < n; k++) {
            c[i][j] += a[i][k] * b[k][j];
        }
    }
}
```

Кэши процессора

- Мало данных, очень быстрый доступ
- Кэши иерархичны: L1, L2, L3
- Обычно из памяти зачитывается сразу *кэш-линия* (64 байта)
- LRU (least recently used) для вытеснения данных

Кэши процессора

- L1 кэш: per-core кэш, обычно разделён на кэш инструкций (L1i) и кэш данных (L2d), доступ: ~3 цикла, ~0.5 ns
- L2 кэш: больше по размеру, может разделяться на несколько ядер, доступ: ~12 циклов, ~4-7 ns
- L3 кэш: ещё больше по размеру (1-8 Mb), обычно один на процессор, доступ: ~40-80 циклов, ~12-20 ns
- Доступ к DRAM (если известен физический адрес): 50-100 циклов, 16+ ns

Latency Numbers Every Programmer Should Know

L1 cache reference	0.5	ns			
Branch mispredict	5	ns			
L2 cache reference	7	ns			14x L1 cache
Mutex lock/unlock	25	ns			
Main memory reference	100	ns			20x L2 cache, 200x L1 cache
Compress 1K bytes with Snappy	3,000	ns	3 µs		
Read 1 MB sequentially from memory	20,000	ns	20 µs		~50GB/sec DDR5
Read 1 MB sequentially from NVMe	100,000	ns	100 µs		~10GB/sec NVMe, 5x memory
Round trip within same datacenter	500,000	ns	500 µs		
Read 1 MB sequentially from SSD	2,000,000	ns	2,000 µs	2 ms	~0.5GB/sec SSD, 100x memory, 20x NVMe
Read 1 MB sequentially from HDD	6,000,000	ns	6,000 µs	6 ms	~150MB/sec 300x memory, 60x NVMe, 3x SSD
Send 1 MB over 1 Gbps network	10,000,000	ns	10,000 µs	10 ms	
Disk seek	10,000,000	ns	10,000 µs	10 ms	20x datacenter roundtrip
Send packet CA->Netherlands->CA	150,000,000	ns	150,000 µs	150 ms	

`mmap` и `munmap`

- Системные вызовы для выделения/освобождения/изменения защиты виртуальной памяти
- `mmap` выделяет область виртуальной памяти, начиная с адреса `addr` длиной `length` байт
- `prot` определяют *флаги защиты страницы*
- `flags` определяют *как* будет страница замапплена

```c
#include <sys/mman.h>

void* mmap(void* addr, size_t len, int prot, int flags, int fd, off_t off);
int munmap(void* addr, size_t length);
int mprotect(void* addr, size_t len, int prot);
```

`mmap`: `prot`

- `PROT_EXEC` — процессы могут выполнять код на этой странице
- `PROT_READ` — страница будет доступна на чтение
- `PROT_WRITE` — страница будет доступна на запись
- `PROT_NONE` — к странице никак нельзя будет обратиться

On-demand paging и minor page fault

- При `mmap` ОС не обязана выделять всю запрошенную память сразу
- Вместо Linux сохраняет у себя ещё одну структуру – `virtual memory area`, которая запоминает регионы выделений памяти
- В таблицах страниц нет выделенных адресов, поэтому процессор генерирует специальное исключение при первом обращении – *page fault*
- В терминологии Linux это называется *minor page fault*

Overcommit

- Т.к. память не выделяется сразу, процессы могут выделить памяти больше, чем RAM – такая ситуация называется *overcommit*'ом
- Linux позволяет регулировать поведение overcommit: полностью его выключать, ограничивать количество выделяемой памяти или давать полную свободу процессам
- `sysctl vm.overcommit_memory` / `sysctl vm.overcommit_ratio` `vm.overcommit_kbytes`
- В Windows нет overcommit

Файл подкачки

- Файл подкачки (он же swap file) – специальный файл или раздел, располагающийся на диске
- Неиспользуемые или редко используемые страницы могут быть сброшены в этот файл, чтобы освободить память для других процессов
- Теперь некоторые доступы к памяти требуют чтения с диска!
- В условиях memory pressure это может приводить к странным последствиям

Отображение файлов (файловые маппинги)

- Кроме выделения памяти POSIX позволяет **отображать файлы в память**
- Для этого в `mmap` надо указать `fd` и `offset`, `flags = MAP_FILE`
- По этому адресу памяти в текущем пространстве будет лежать (изменяемая) копия файла
- Любые изменения файла будут моментально отражены в памяти и видны всем остальным процессам

Major page faults

- Для файловых маппингов тоже используется аналог on-demand paging: при первом обращении генерируется page fault, ядро перехватывает исключение, читает с диска файл, копирует его в память и возвращает управление в процесс
- Такой page fault называют мажорным (major page fault)

Page cache

- Механизм ядра для кэширования чтений с диска
- Page cache оперирует страницами
- Страницы с данными файла из всех процессов ссылаются на один и тот же фрейм, поэтому изменения файлов (в том числе через write) видны во всей ОС сразу
- Все записи/чтения проходят через page cache
- ОС старается как можно больше данных оставлять в page cache
- В случае нехватки памяти, страницы из page cache могут быть *вытеснены*

Writeback

- `write` и запись в файловый маппинг не гарантируют, что данные были в реальности записаны на диск
- Вместо этого они помечаются как изменённые (dirty)
- ОС периодически сбрасывает dirty страницы на диск (раз в несколько десятков миллисекунд)
- Вытеснение dirty страниц требует записи на диск

Синхронизация данных

- `fsync` гарантирует, что данные были записаны на диск
- `fdatasync` сбрасывает только данные на диск (нет гарантии о записи метаданных)
- `sync` записывает все изменения на диск

```c
#include <unistd.h>

int fsync(int fd);
int fdatasync(int fd);

int sync();
```

`mmap`: `MAP_SHARED` vs `MAP_PRIVATE`

- Если указан `MAP_PRIVATE`, то маппинг – приватный: изменения в маппинге *не* видны другим процессам
- `MAP_FILE | MAP_PRIVATE` – запись в маппинг не будет изменять файл
- Если указан `MAP_SHARED`, то маппинг – *разделяемый*: изменения в маппинге видны другим процессам
- `MAP_SHARED | MAP_ANONYMOUS` страницы разделяются детьми процесса-родителя после `fork`

`mmap`: другие флаги

- `MAP_FIXED`: по-умолчанию ОС не даёт гарантий, что будет выделен именно запрашиваемый адрес при `MAP_FIXED` – гарантирует или выдаст ошибку
- `MAP_POPULATE`: выделить страницы под маппинг сразу

Адресное пространство процесса

- Нулевой адрес нельзя замапить (`NULL` имеет особый смысл)
- Код и данные располагаются в одном адресном пространстве
- Разделения памяти условные (для ОС всё это – просто памаять)
- Ядро всегда располагается в верхних адресах (higher-half kernel)

Файлы в `procfs`

- `/proc/<pid>/maps` хранит текущие virtual memory areas
- `/proc/<pid>/status` содержит статус процесса, есть куча информации о памяти: пиковое потребление, сколько сей
- `/proc/<pid>/mem` представляет собой память процесса (её можно читать и писать)
- `/proc/<pid>/map_files` хранит список файлов, которые замапленны в процесс

Go raibh maith agat!

«Спасибо» на ирландском языке